

Decision Trees

Логическая закономерность (Rule)

$$R_y: X \rightarrow \{0, 1\}$$

Виды закономерностей

Пороговые условия:

$$R(x) = [a \leq x_i \leq b]$$

Синдром пороговых условий:

$$R(x) = \left[\sum_{j \in J} [a_j \leq x_j \leq b_j] \geq d \right]$$

При $d = |J|$ - конъюнкция условий.

Оценки правил (классификаторов)

		y_i		
		$= y$	$\neq y$	
$R_y(x_i)$	1	True positive (TP)	False positive (FP)	Positive predictive value, Precision $\frac{TP}{TP + FP}$
	0	False negative (FN)	True negative (TN)	
		True positive rate, Recall $\frac{TP}{TP + FN}$		Accuracy $\frac{TP + TN}{TP + FP + TN + FN}$

$$F_1score = \frac{2}{\frac{1}{recall} + \frac{1}{precision}} = 2 \frac{precision * recall}{precision + recall} = \frac{2TP}{2TP + FP + FN}$$

Пример

		y_i		
		$= y$	$\neq y$	
$R_y(x_i)$	1	0 (TP)	0 (FP)	Positive predictive value, Precision 0
	0	50 (FN)	950 (TN)	
		True positive rate, Recall 0		Accuracy 95%

$F_1score = 0$

Пример #2

		y_i		
		$= y$	$\neq y$	
$R_y(x_i)$	1	50 (TP)	950 (FP)	Positive predictive value, Precision 5%
	0	0 (FN)	0 (TN)	
		True positive rate, Recall 100%		Accuracy 5%

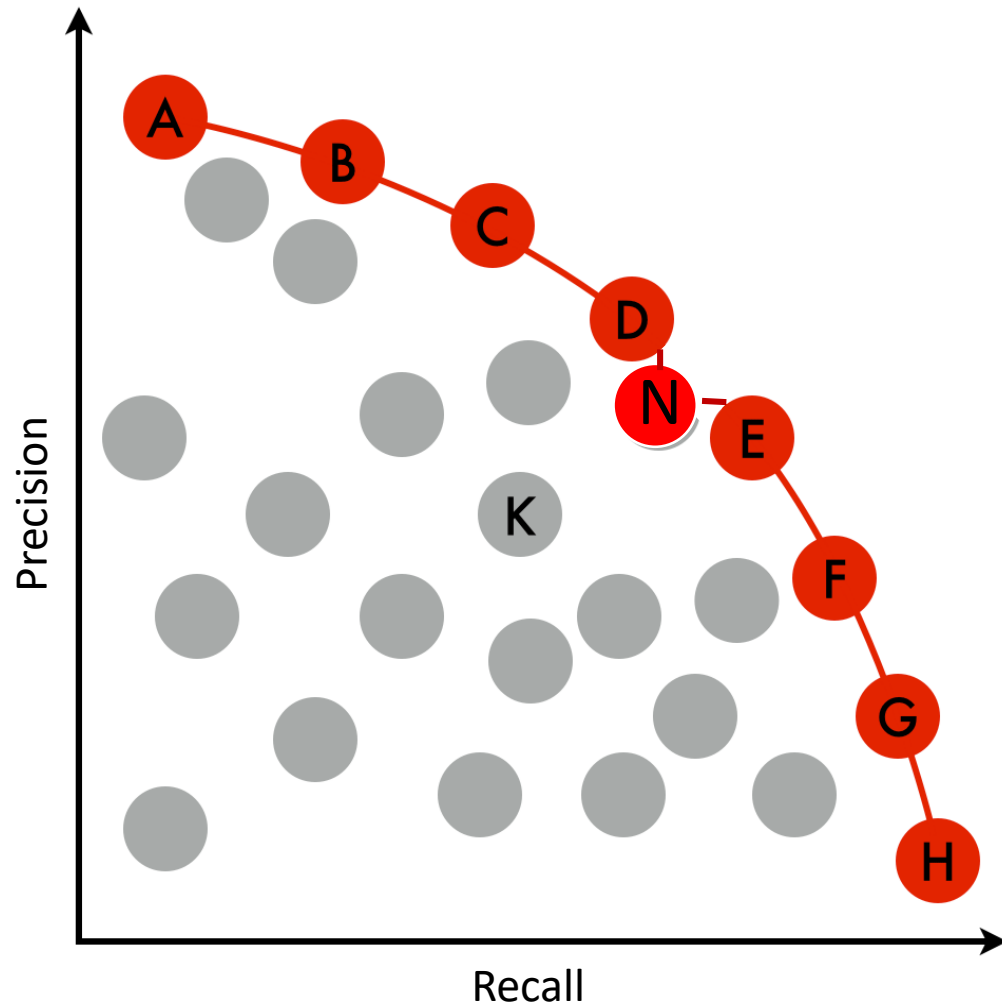
$$F_1score = 10\%$$

Пример #3

		y_i		
		$= y$	$\neq y$	
$R_y(x_i)$	1	25 (TP)	475 (FP)	Positive predictive value, Precision 5%
	0	25 (FN)	475 (TN)	
		True positive rate, Recall 50%		Accuracy 50%

$F_1score = 9\%$

Эффективность по Парето



● - Парето фронт, 1-я линия

N – тоже 1-я линия, K – 2-я

Эффективное по Парето правило – такое, что нет другого правила, у которого одновременно выше и precision и recall.

Оценки правил (классификаторов)

		y_i		
		$= y$	$\neq y$	
$R_y(x_i)$	1	True positive (TP)	False positive (FP)	Positive predictive value, Precision $\frac{TP}{TP + FP}$
	0	False negative (FN)	True negative (TN)	
		True positive rate, Recall $\frac{TP}{TP + FN}$	False positive rate $\frac{FP}{FP + TN}$	Accuracy $\frac{TP + TN}{TP + FP + TN + FN}$

$$F_1score = \frac{2}{\frac{1}{recall} + \frac{1}{precision}} = 2 \frac{precision * recall}{precision + recall} = \frac{2TP}{2TP + FP + FN}$$

Пример #1

		y_i		
		$= y$	$\neq y$	
$R_y(x_i)$	1	0 (TP)	0 (FP)	Positive predictive value, Precision 0%
	0	50 (FN)	950 (TN)	
		True positive rate, Recall 0%	False positive rate 0%	Accuracy 95%

$$F_1score = 0$$

Пример #2

		y_i		
		$= y$	$\neq y$	
$R_y(x_i)$	1	50 (TP)	950 (FP)	Positive predictive value, Precision 5%
	0	0 (FN)	0 (TN)	
		True positive rate, Recall 100%	False positive rate 100%	Accuracy 5%



$$F_1score = 10\%$$

Пример #3



		y_i		
		$= y$	$\neq y$	
$R_y(x_i)$	1	25 (TP)	475 (FP)	Positive predictive value, Precision 5%
	0	25 (FN)	475 (TN)	
		True positive rate, Recall 50%	False positive rate 50%	Accuracy 50%

$$F_1score = 9\%$$

ROC (Receiver Operating Characteristic)



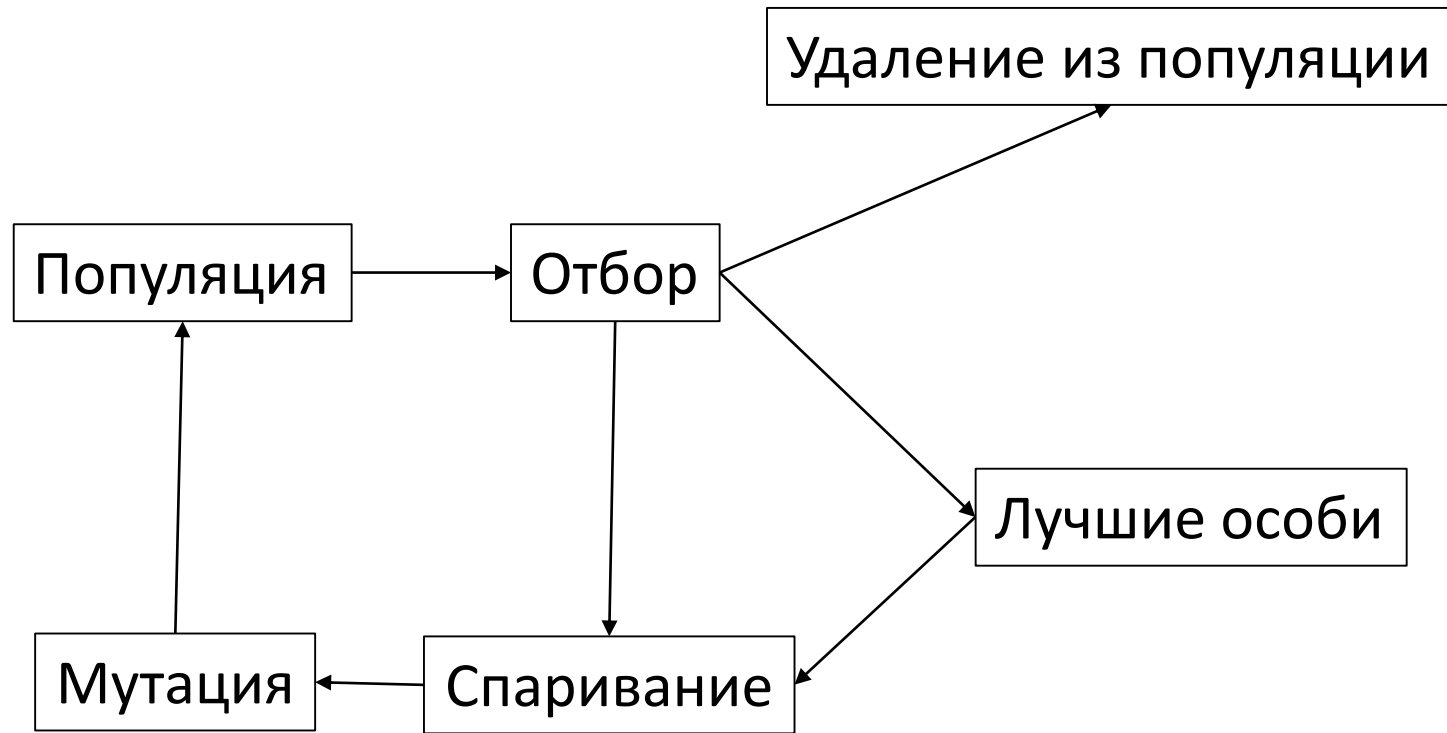
ROC (Receiver Operating Characteristic)



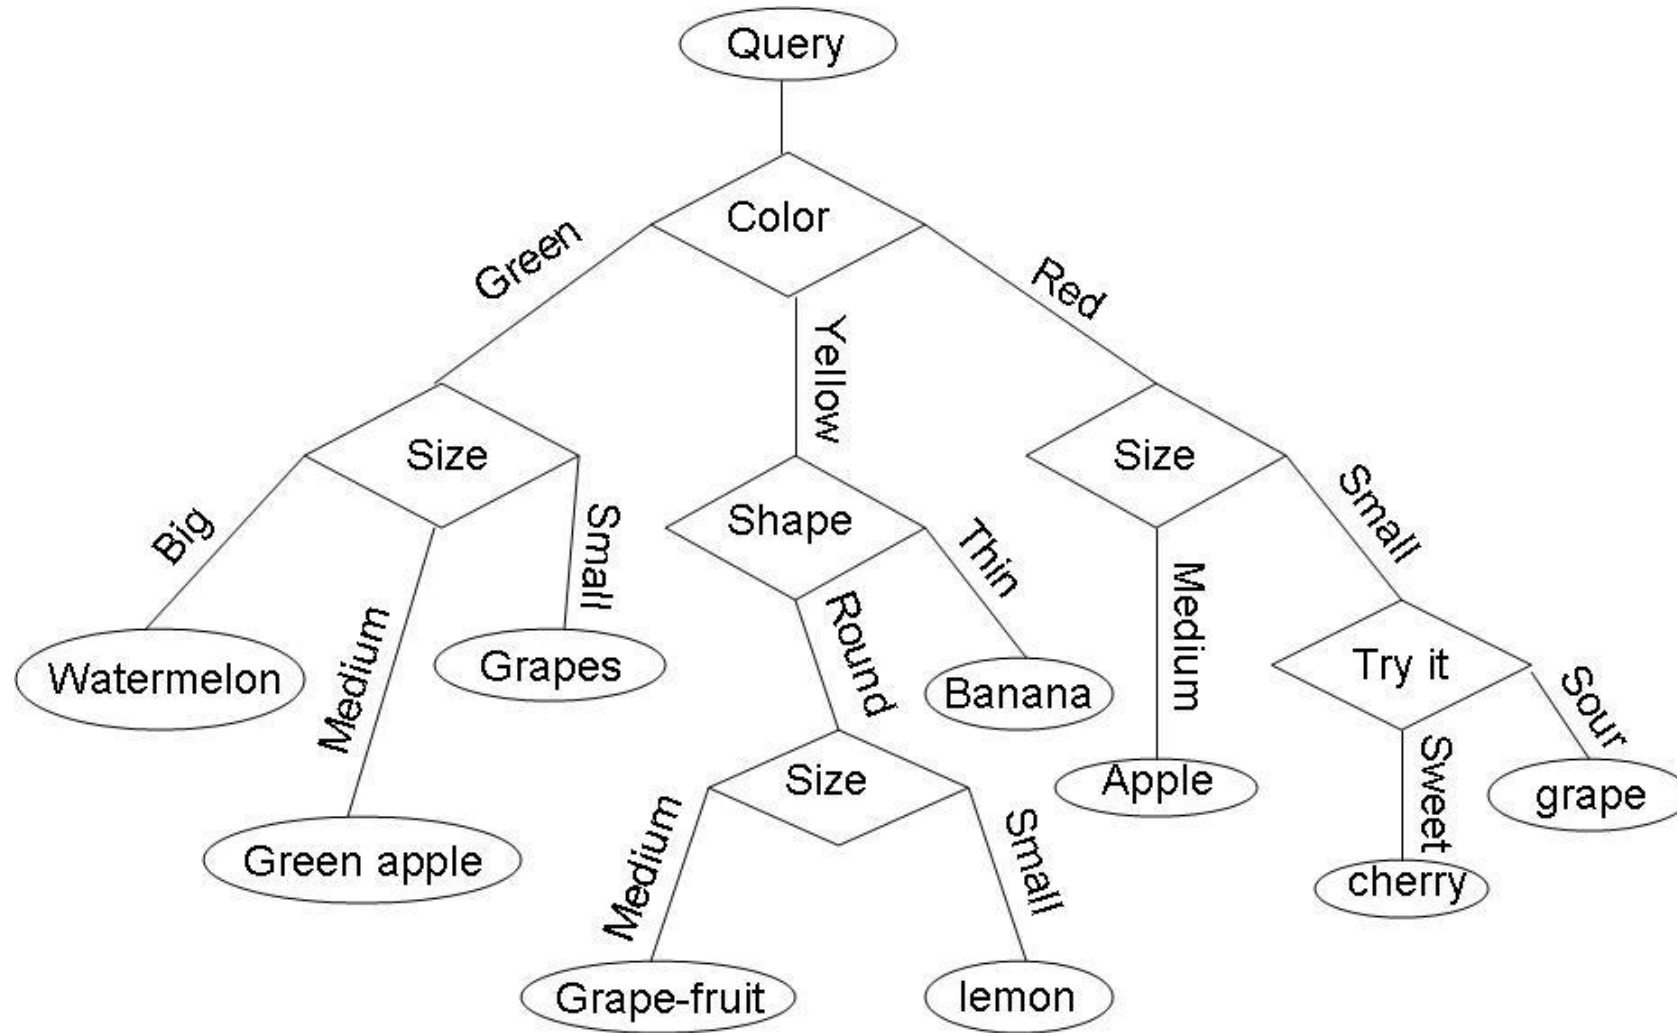
AUC – Area Under the ROC Curve

Отбор и генерация правил

Генетический алгоритм



Дерева решений



Оценки логических закономерностей

Information Gain (критерий информационного выигрыша):

$$IG(R) = H(X) - \frac{|R^1|}{|X|} H(R^1) - \frac{|R^0|}{|X|} H(R^0)$$

$$H(X) = - \sum_{y \in Y} \frac{|x_i: y_i = y|}{|X|} \times \log_2 \frac{|x_i: y_i = y|}{|X|} \quad - \text{энтропия}$$

Gini impurity (критерий Джини)

$$I_g(X) = \sum_{y \in Y} \frac{|x_i: y_i = y|}{X} \frac{|x_i: y_i \neq y|}{X}$$

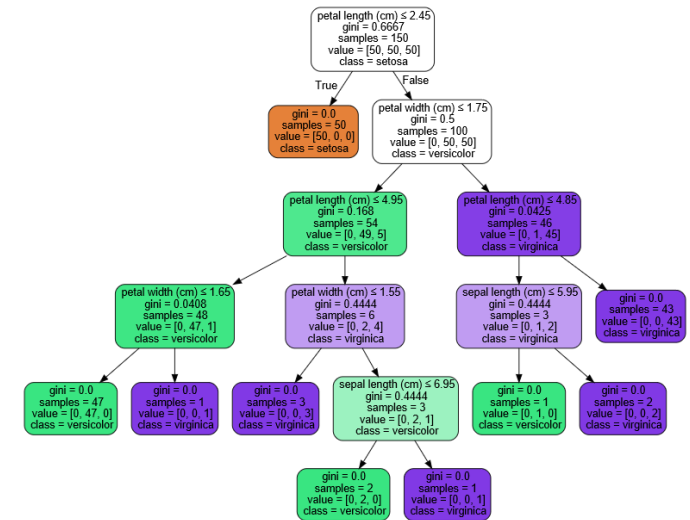
Вероятность того, что мы ошибемся, если будем элементам из множества приписывать класс согласно распределению классов в множестве.

Алгоритмы ID3 и C4.5 (Iterative Dichotomizer 3 и C4.5)

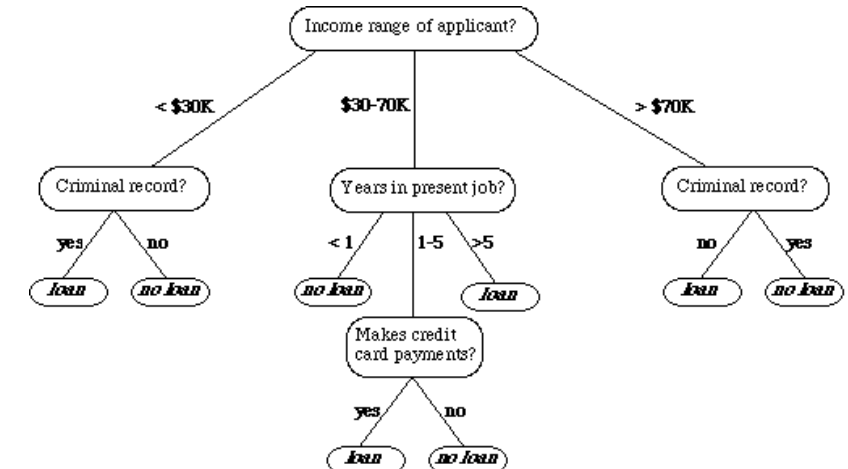
Автор: John Ross Quinlan

1. Если все объекты лежат в одном классе → вернуть лист с этим классом.
2. Найти правило с лучшим нормализованным информационным выигрышем или по Джини.
3. Правила с информационным выигрышем нет → вернуть лист с мажоритарным классом.
4. Разделить по этому правилу объекты.
5. Вызвать 1. для каждого листа, на который разделены объекты.

ID3



C4.5



Алгоритм CART



(Classification and Regression Trees)

Дисперсия:

$$V(X) = \frac{1}{|X|^2} \sum_{x_i \in X} \sum_{x_j \in X} \frac{1}{2} (y_i - y_j)^2$$

Пример работы

Decision surface of a decision tree using paired features



Regularization and Train\Test

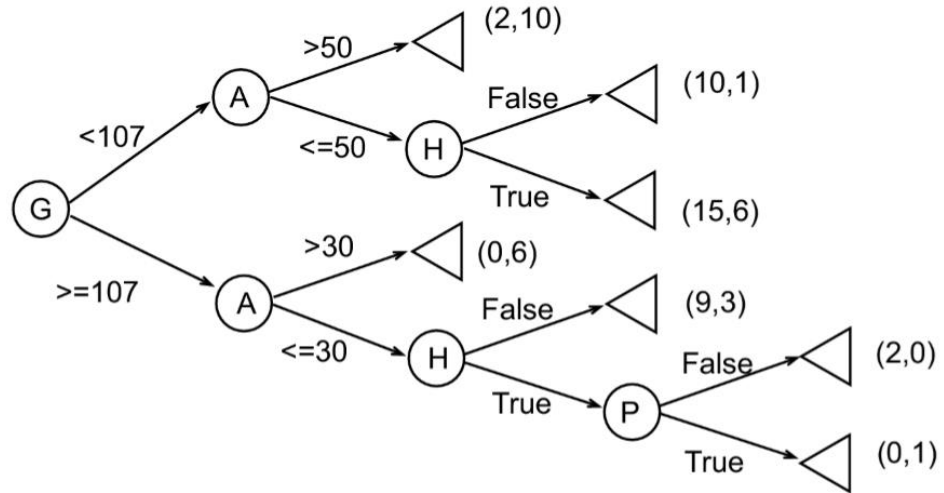
Выделим долю точек ($\approx 10 - 20\%$) в отдельную выборку - Test.

Обучать будем на оставшихся – Train.

По метрике на Test можно оптимизировать параметры модели (дерева), например – максимальную глубину.

Oblivious Decision Trees (Небрежные решающие деревья)

На одном уровне – одинаковые признаки.

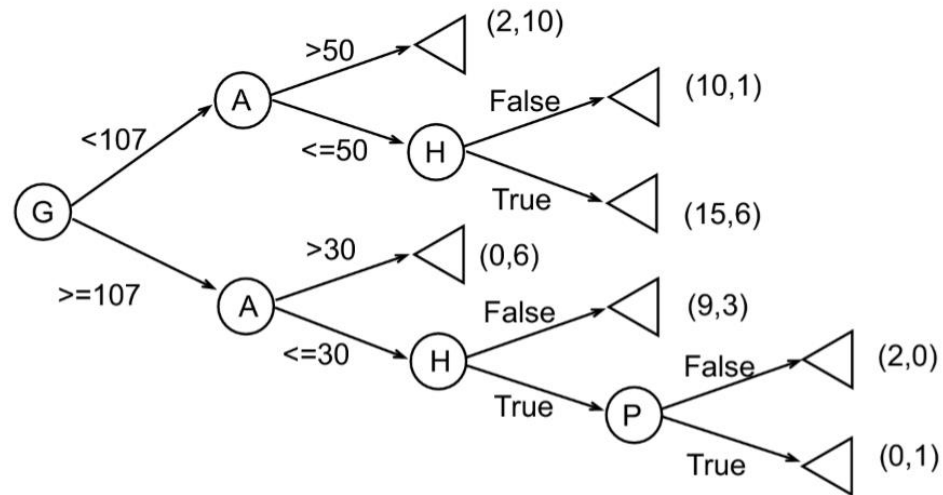


(G)lucose level
(A)ge
(H)ypertension
(P)regnancy

Oblivious Decision Trees

(Небрежные решающие деревья)

На одном уровне – одинаковые признаки.



(G)lucose level
(A)ge
(H)ypertension
(P)regnancy

MatrixNet (Yandex) – Oblivious Decision Trees, где правило для разделения тоже одинаковое на каждом уровне. В этом случае порядок правил не важен и оценку и удаление признаков легко организовать.

Random Forests (Случайные леса)

Обучим много деревьев на «случайных данных»


Случайные данные:

1) Датасеты с помощью **bagging (bootstrap aggregating)** – вытаскиваем из исходного датасета столько же данных, но с повторениями.

2) Берем случайное подмножество признаков.

Результат – голосование, вероятность, логарифм вероятностей.

Параметры – количество используемых примеров и признаков для построения каждого дерева.



Немножко истории статистики

Sampling Случайная выборка

Jackknife resampling
(John Tukey, 1958)

Выкидываем поочередно по одному примеру

«like a Boy Scout's jackknife, it is a "rough and ready" tool that can solve a variety of problems even though specific problems may be more efficiently solved with a purpose-designed tool»

Bootstrapping (Bootstrap resampling)
(Bradley Efron, 1979)
«to pull oneself up by one's bootstraps»

Набираем выборку того же размера
с повторениями из исходной

Bagging (**B**ootstrap **AGG**regat**ING**)
(Leo Breiman, 1994)

Используем разные bootstrap*
выборки для обучения