


Регрессия

Линейная регрессия

$$E_{in}(h, \mathbf{x}) = (h(\mathbf{x}) - f(\mathbf{x}))^2$$

$$E_{in}(\mathbf{w}) = \frac{1}{N} \sum_{i=1}^N (\mathbf{w}^T \mathbf{x}_i - y_i)^2 = \frac{1}{N} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2$$

$$\mathbf{X} = \begin{bmatrix} - & \mathbf{x}_1^T & - \\ - & \mathbf{x}_2^T & - \\ & \vdots & \\ - & \mathbf{x}_N^T & - \end{bmatrix} \quad \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix}$$



Линейная регрессия

$$E_{in}(\mathbf{w}) = \frac{1}{N} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2$$

$$\nabla E_{in}(\mathbf{w}) = \frac{2}{N} \mathbf{X}^T (\mathbf{X}\mathbf{w} - \mathbf{y}) = 0$$

$$\mathbf{X}^T \mathbf{X} \mathbf{w} = \mathbf{X}^T \mathbf{y}$$

$$\mathbf{w} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}, \quad \mathbf{w} = \mathbf{X}^\dagger \mathbf{y}$$


Полиномиальная регрессия

$$X \rightarrow Z$$




$$x \rightarrow [1, x, x^2]$$

$$[x_1, x_2] \rightarrow [1, x_1, x_2, x_1^2, x_2^2, x_1 x_2]$$



etc...





Полиномиальная регрессия





Цель - синус



Цель - синус



Цель - синус



Bias and Variance

$$E_{out}(h^D) = \mathbb{E}_{\mathbf{x}} \left[(h^D(\mathbf{x}) - f(\mathbf{x}))^2 \right] \text{ (D - датасет)}$$

$$\mathbb{E}_D[E_{out}(h^D)] = \mathbb{E}_D \left[\mathbb{E}_{\mathbf{x}} \left[(h^D(\mathbf{x}) - f(\mathbf{x}))^2 \right] \right] = \mathbb{E}_{\mathbf{x}} \left[\mathbb{E}_D \left[(h^D(\mathbf{x}) - f(\mathbf{x}))^2 \right] \right]$$

$$\bar{h}(\mathbf{x}) = \mathbb{E}_D[h^D(\mathbf{x})] \text{ (средняя гипотеза)}$$

$$\begin{aligned} \mathbb{E}_D \left[(h^D(\mathbf{x}) - f(\mathbf{x}))^2 \right] &= \mathbb{E}_D \left[\left(h^D(\mathbf{x}) - \bar{h}(\mathbf{x}) + \bar{h}(\mathbf{x}) - f(\mathbf{x}) \right)^2 \right] = \\ &= \mathbb{E}_D \left[\left(h^D(\mathbf{x}) - \bar{h}(\mathbf{x}) \right)^2 + \left(\bar{h}(\mathbf{x}) - f(\mathbf{x}) \right)^2 + 2 \left(h^D(\mathbf{x}) - \bar{h}(\mathbf{x}) \right) \left(\bar{h}(\mathbf{x}) - f(\mathbf{x}) \right) \right] = \\ &= \mathbb{E}_D \left[\left(h^D(\mathbf{x}) - \bar{h}(\mathbf{x}) \right)^2 \right] + \left(\bar{h}(\mathbf{x}) - f(\mathbf{x}) \right)^2 \end{aligned}$$

Bias and Variance

$$\mathbb{E}_D \left[\left(h^D(\mathbf{x}) - f(\mathbf{x}) \right)^2 \right] = \mathbb{E}_D \left[\left(h^D(\mathbf{x}) - \bar{h}(\mathbf{x}) \right)^2 \right] + \left(\bar{h}(\mathbf{x}) - f(\mathbf{x}) \right)^2$$

$$\mathbb{E}_D[E_{out}(h^D)] = \mathbb{E}_{\mathbf{x}} \left[\mathbb{E}_D \left[\left(h^D(\mathbf{x}) - f(\mathbf{x}) \right)^2 \right] \right] = \mathbb{E}_{\mathbf{x}} \left[\mathbb{E}_D \left[\left(h^D(\mathbf{x}) - \bar{h}(\mathbf{x}) \right)^2 \right] + \left(\bar{h}(\mathbf{x}) - f(\mathbf{x}) \right)^2 \right] =$$

$$= \mathbb{E}_{\mathbf{x}}[variance(\mathbf{x}) + bias(\mathbf{x})] = bias + variance$$


$$bias = \mathbb{E}_{\mathbf{x}} \left[\left(\bar{h}(\mathbf{x}) - f(\mathbf{x}) \right)^2 \right]$$

$$variance = \mathbb{E}_{\mathbf{x}} \left[\mathbb{E}_D \left[\left(h^D(\mathbf{x}) - \bar{h}(\mathbf{x}) \right)^2 \right] \right]$$



Bias and Variance

$$variance = \mathbb{E}_{\mathbf{x}} \left[\mathbb{E}_D \left[\left(h^D(\mathbf{x}) - \bar{h}(\mathbf{x}) \right)^2 \right] \right]$$


$$bias = \mathbb{E}_{\mathbf{x}} \left[\left(\bar{h}(\mathbf{x}) - f(\mathbf{x}) \right)^2 \right]$$



Цель - синус




Цель - синус



bias = **0.50**

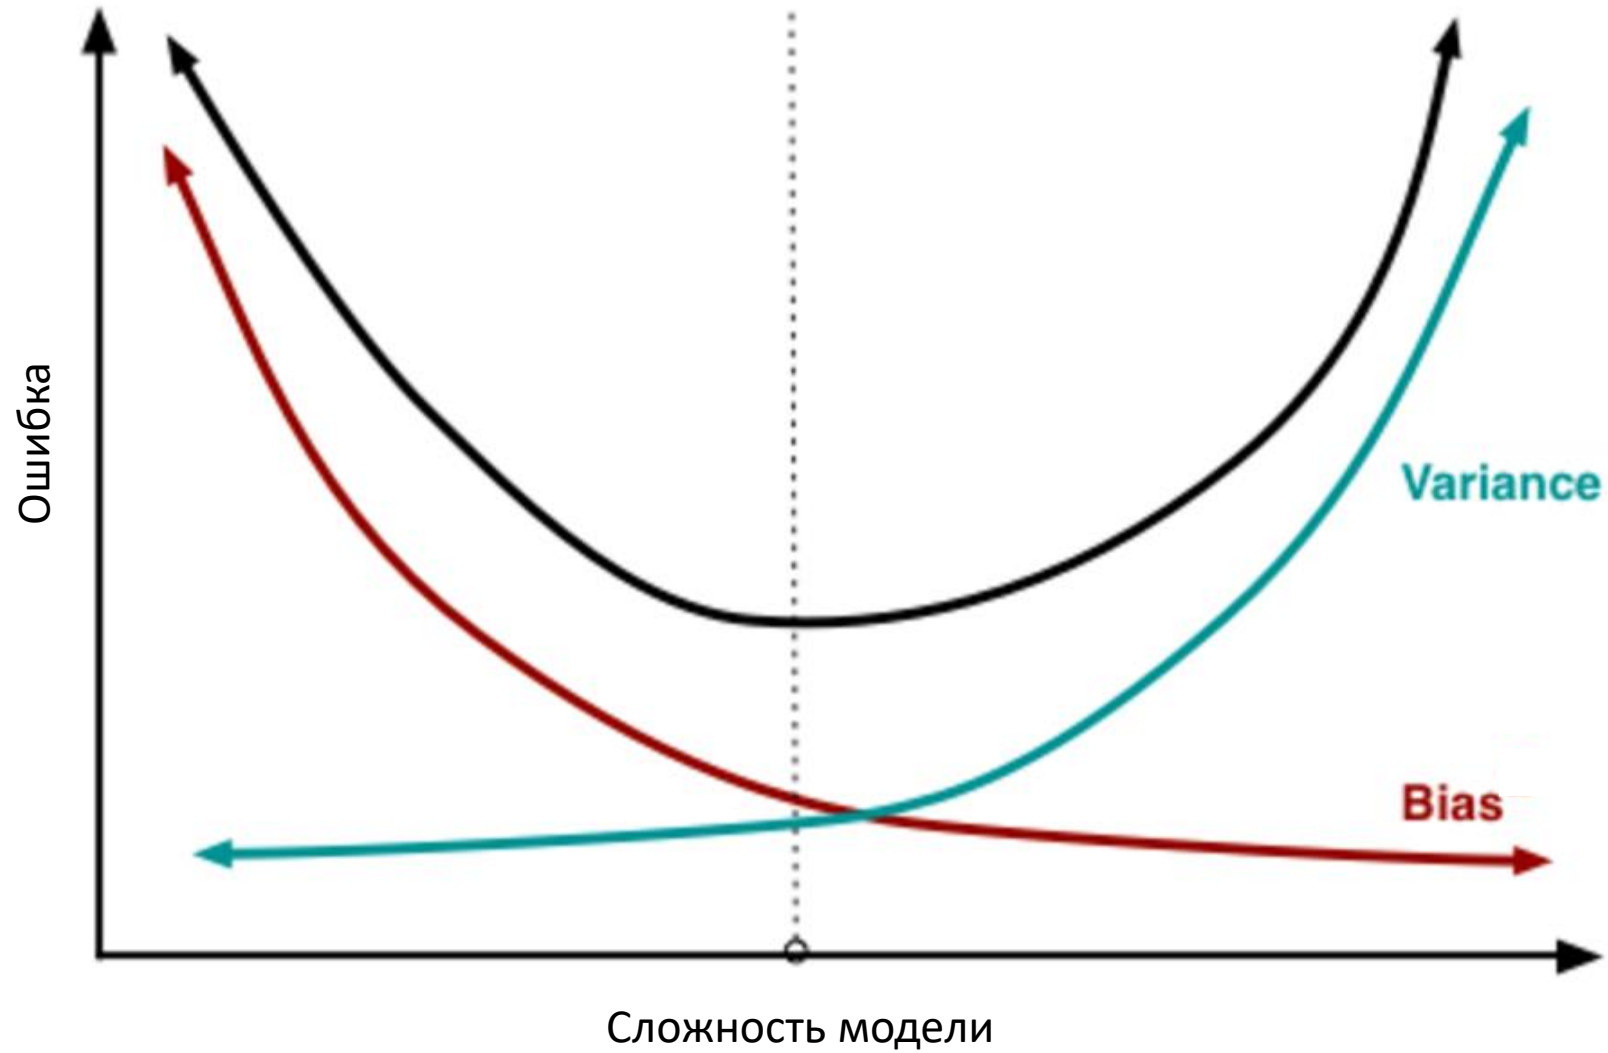
var = **0.25**



bias = **0.21**

var = **1.69**

Bias and Variance



Регуляризация регрессии

Регрессия. Регуляризация.


$$E_{in}(\mathbf{w}) = \frac{1}{N} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2$$

$$E_{in}(\mathbf{w}) + \frac{\alpha}{N} \mathbf{w}^T \mathbf{w} = \frac{1}{N} \left((\mathbf{X}\mathbf{w} - \mathbf{y})^T (\mathbf{X}\mathbf{w} - \mathbf{y}) + \alpha \mathbf{w}^T \mathbf{w} \right)$$

$$\nabla E_{in}(\mathbf{w}) = \frac{2}{N} (\mathbf{X}^T (\mathbf{X}\mathbf{w} - \mathbf{y}) + \alpha \mathbf{w}) = 0$$


$$\mathbf{w} = (\mathbf{X}^T \mathbf{X} + \alpha \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y}$$

Регуляризация и синус



bias = **0.21**

var = **1.69**




bias = **0.23**

var = **0.33**


Переобучение и недообучение

$$E_{in}(\mathbf{w}) + \frac{\alpha}{N} \mathbf{w}^T \mathbf{w}$$


$\alpha = 0$




$\alpha = 0.0001$



$\alpha = 0.01$




$\alpha = 1$



Гребневая (Ridge) регрессия


$$E_{in} = \frac{1}{N} \|Xw - Y\|_2^2 + \frac{\alpha}{N} \|w\|_2^2$$

$$w = (X^T X + \alpha I)^{-1} X^T Y$$



Гребневая (Ridge) регрессия

$$E_{in} = \frac{1}{2N} \|Xw - Y\|_2^2 + \alpha \|w\|_2^2$$




LASSO

(Least Absolute Shrinkage and Selection Operator)

$$E_{in} = \frac{1}{2N} \|Xw - Y\|_2^2 + \alpha \|w\|_1$$


Применяется покоординатный спуск или LARS.



LARS (Least Angle Regression)

1. Возьмем x_i наиболее сильно коррелирующий с y .
2. Сдвигаем коэффициент β_1 при x_i в сторону корреляции пока корреляция x_i с остаточным значением $r = y - \hat{y}$ остается максимальной.
3. В тот момент, как корреляция перестает быть максимальной, появляется еще один (или несколько) признак x_j с такой же корреляцией.
4. Вводим коэффициент β_2 при $(x_i \pm x_j)$.
5. $\rightarrow 2$

LARS




LASSO

(Least Absolute Shrinkage and Selection Operator)


$$E_{in} = \frac{1}{2N} \|Xw - Y\|_2^2 + \alpha \|w\|_1$$

Применяется покоординатный спуск или LARS.




Elastic Net

$$E_{in} = \frac{1}{2N} \|Xw - Y\|_2^2 + \frac{1}{2} \alpha(1 - l1_{ratio}) \|w\|_2^2 + \alpha(l1_{ratio}) \|w\|_1$$




CART

$$\nabla V(R) = \frac{1}{N^2} \sum \sum \frac{1}{2} (y_i - y_j)^2 - \left(\frac{1}{N_1^2} \sum \sum \frac{1}{2} (y'_i - y'_j)^2 + \frac{1}{N_2^2} \sum \sum \frac{1}{2} (y''_i - y''_j)^2 \right)$$



Support Vector Regression Machine

$$\begin{cases} \frac{1}{2} \|w\|^2 + C \sum (\xi_i + \xi_i^*) \rightarrow \min \\ y_i - w^T x_i - b \leq \epsilon + \xi_i \\ w^T x_i + b - y_i \leq \epsilon + \xi_i^* \\ \xi_i, \xi_i^* \geq 0 \end{cases}$$



R^2 -score (коэффициент детерминации)

Абсолютное значение ошибки довольно неинформативно.

Удобная оценка результата регрессии:

$$R^2 = 1 - \frac{u}{v}$$

$$u = \sum (h(x_i) - y_i)^2 \quad v = \sum (\bar{y} - y_i)^2 \quad \bar{y} = \frac{1}{N} \sum y_i$$